TECH CHALLENGE | FASE 2 | FIAP PÓS TECH

Classificação da qualidade de vinhos com Machine Learning

Relatório técnico

EQUIPE

Vitor Hugo Ramos Guerra
Reinaldo Souza Lima Filho
Rodrigo de Castro Souza
Robinson de Freitas Castro Junior
Vinicius Jacomini Vaccari

Novembro de 2026

Sumário

1. Introdução **3**

Objetivo . . . 3

Resumo dos resultados . . . 3

2. Base de dados **4**

Variável alvo . . . 4

3. Análise exploratória **5**

3.1 Qualidade dos dados . . . 5

3.2 Distribuições e outliers . . . 5

3.3 Balanceamento das classes . . . 6

3.4 Correlações . . . 6

3.5 Comparação entre as classes . . . 7

4. Metodologia **9**

4.1 Pré-processamento . . . 9

4.2 Validação e escolha de hiperparâmetros . . . 9

4.3 Prevenção de vazamento de dados . . . 10

5. Resultados **10**

5.1 Validação cruzada . . . 10

5.2 Conjunto de teste . . . 11

5.3 Discussão . . . 12

6. Interpretação **12**

7. Implicações para a produção **13**

Próximos passos . . . 14

Limitações . . . 14

8. Conclusão **14**

Referências . . . 14

CONTEXTO

1. Introdução

A avaliação da qualidade de vinhos é feita tradicionalmente por especialistas, em análises sensoriais que consideram aroma, sabor, acidez e equilíbrio. O processo é importante, mas é subjetivo, demorado e depende da experiência de quem avalia. Além disso, a nota só é conhecida no final da produção, quando já não é possível corrigir o lote.

Durante a produção, por outro lado, o laboratório já mede diversas características físico-químicas de cada vinho. Neste trabalho investigamos se essas medições permitem prever a qualidade final, para apoiar enólogos e produtores na tomada de decisão e na padronização do processo.

Objetivo

Desenvolver e comparar modelos de classificação capazes de prever se um vinho é de alta qualidade (nota maior ou igual a 7) ou de baixa/média qualidade (nota menor que 7) a partir de suas características físico-químicas, e identificar quais variáveis mais influenciam a qualidade.

Resumo dos resultados

- A base tem 1143 registros de vinhos tintos, dos quais 125 eram duplicados. Após a limpeza ficamos com 1018 vinhos, sendo 137 (13,5%) de alta qualidade.
- O teor alcoólico e a acidez volátil são os sinais mais fortes de qualidade: vinhos com mais álcool e menos acidez volátil têm chance muito maior de serem bem avaliados.
- Comparamos KNN, Regressão Logística e Random Forest. O Random Forest teve o melhor F1 na validação cruzada (0,551) e, no teste, identificou 74% dos vinhos de alta qualidade com ROC-AUC de 0,92.
- As variáveis mais importantes foram álcool, acidez volátil e sulfatos, o que aponta para maturação e fermentação, controle de contaminação e uso equilibrado de conservantes como pontos de atenção na produção.

DADOS

2. Base de dados

Utilizamos o Wine Quality Dataset, disponível no Kaggle (arquivo WineQT.csv). Cada registro corresponde a um vinho tinto com 11 medições físico-químicas, a nota atribuída por especialistas (quality, de 0 a 10) e um identificador (Id).

Variável	Descrição	Unidade
fixed acidity	Acidez fixa (ácidos não voláteis, como tartárico e málico)	g/L
volatile acidity	Acidez volátil (principalmente ácido acético)	g/L
citric acid	Ácido cítrico	g/L
residual sugar	Açúcar que restou após a fermentação	g/L
chlorides	Cloretos (sal)	g/L
free sulfur dioxide	SO2 livre, parte ativa do conservante	mg/L
total sulfur dioxide	SO2 total (livre + combinado)	mg/L
density	Densidade	g/cm³
pH	pH	-
sulphates	Sulfatos	g/L
alcohol	Teor alcoólico	% vol.
quality	Nota dos especialistas	0 a 10

Variável alvo

Conforme o enunciado, a nota foi transformada em uma classificação binária: high_quality = 1 quando a nota é maior ou igual a 7 e 0 caso contrário. A coluna quality foi retirada das variáveis de entrada, já que é a própria resposta.

As notas se concentram em 5 e 6 e não há notas abaixo de 3 nem acima de 8. Com o corte em 7, a classe de alta qualidade fica bem menor que a outra, o que orientou várias decisões da modelagem.

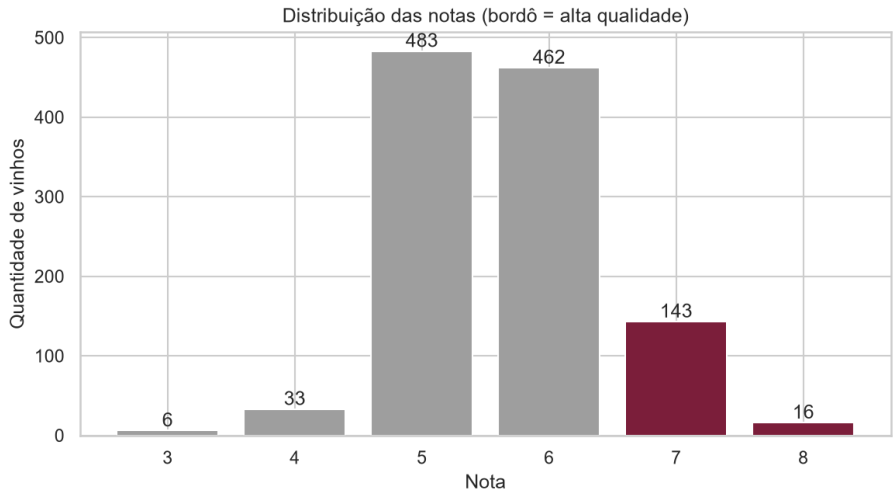


Figura 1. Distribuição das notas. Em bordô, as notas consideradas de alta qualidade.

ANÁLISE EXPLORATÓRIA

3. Análise exploratória

3.1 Qualidade dos dados

Não há valores faltantes. Encontramos 125 linhas duplicadas (10,9% da base): registros com as mesmas 11 medições e a mesma nota, diferindo apenas no Id. Removemos essas linhas porque uma cópia poderia cair no treino e outra no teste, o que inflaria as métricas (vazamento de dados).

Também verificamos regras de consistência física e química: valores negativos, SO2 livre maior que o total, ácido cítrico maior que a acidez fixa, pH, densidade e álcool fora de faixas plausíveis. Nenhuma regra foi violada.

3.2 Distribuições e outliers

Densidade e pH têm distribuição praticamente simétrica. As demais variáveis têm cauda à direita, de forma mais acentuada em cloretos, açúcar residual e sulfatos. As escalas também variam muito (a densidade fica perto de 0,99 e o SO2 total chega a 289), o que torna o escalonamento necessário para modelos baseados em distância ou em combinação linear das variáveis.

Variável	Outliers (critério IQR)	% da base
residual sugar	95	9,3%
chlorides	71	7,0%
sulphates	41	4,0%
fixed acidity	37	3,6%
total sulfur dioxide	33	3,2%

No total, 262 vinhos (25,7%) têm pelo menos um valor fora dos limites do IQR. Optamos por manter esses vinhos: eles não são erros de medição e a proporção de alta qualidade entre eles (17,6%) é maior que na base (13,5%). Removê-los descartaria um quarto da base e justamente uma parte rica na classe

de interesse.

3.3 Balanceamento das classes

13,5% dos vinhos são de alta qualidade (137 de 1018). Um modelo que classificasse todos como baixa/média qualidade teria 86,5% de acurácia sem identificar nenhum vinho bom.

Por causa do desbalanceamento adotamos o F1-score da classe de alta qualidade como métrica principal, usamos divisão e validação cruzada estratificadas e aplicamos peso por classe (class_weight='balanced') nos modelos que oferecem essa opção.

3.4 Correlações

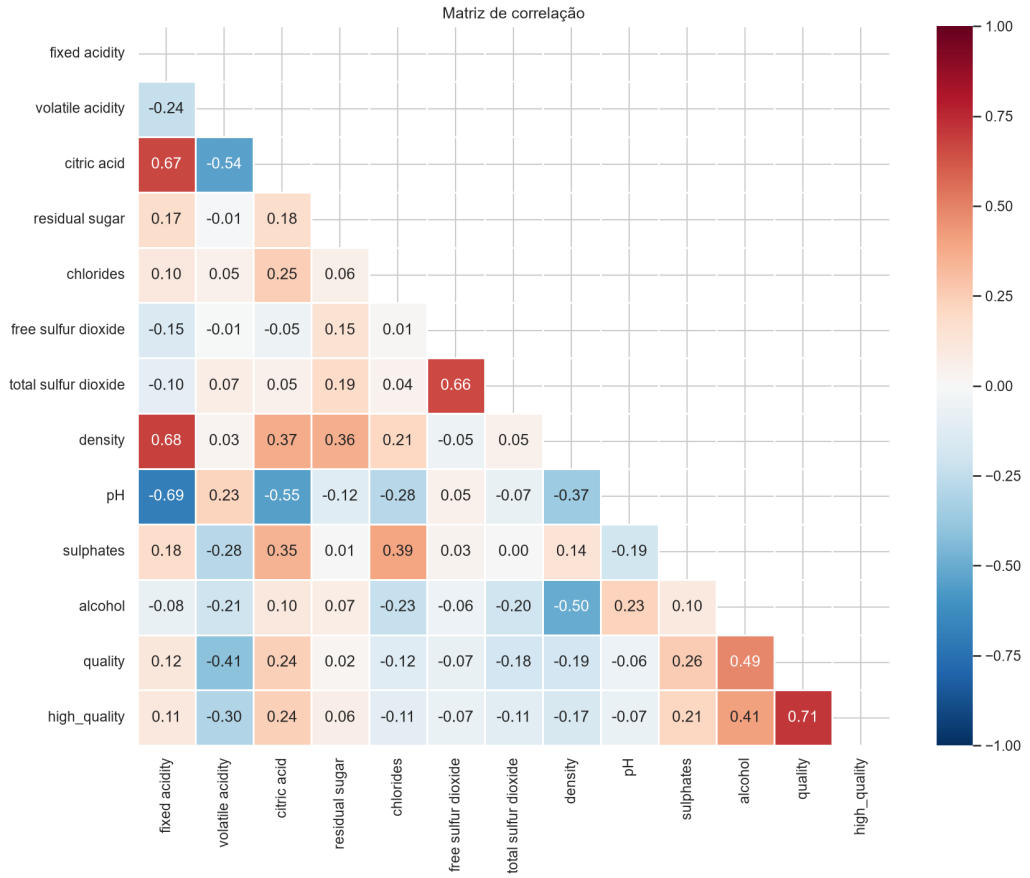


Figura 2. Matriz de correlação de Pearson.

Os pares de variáveis com correlação de pelo menos 0,3 e a justificativa de cada um:

Par	r	Justificativa
Acidez fixa x pH	-0,69	O pH mede a acidez de forma inversa: quanto mais ácido, menor o pH.
Acidez fixa x densidade	0,68	Ácidos dissolvidos tornam o vinho mais denso que a água.
Acidez fixa x ácido cítrico	0,67	O ácido cítrico é um dos ácidos fixos.
SO2 livre x SO2 total	0,66	O SO2 total é a soma do livre com o combinado.

Par	r	Justificativa
Ácido cítrico x pH	-0,55	Mais ácido, pH menor.
Acidez volátil x ácido cítrico	-0,54	Bactérias podem converter ácido cítrico em ácido acético.
Densidade x álcool	-0,50	O álcool é menos denso que a água e é produzido a partir do açúcar, que é mais denso.
Cloretos x sulfatos	0,39	Ambos são sais minerais, ligados à uva, ao solo e ao processo.
Densidade x pH	-0,37	Efeito indireto: vinhos mais ácidos são mais densos e têm pH menor.
Ácido cítrico x densidade	0,37	Mais substância dissolvida aumenta a densidade.
Açúcar residual x densidade	0,36	Açúcar dissolvido aumenta a densidade.
Ácido cítrico x sulfatos	0,35	Provável relação de processo: correção de acidez e adição de sulfitos costumam ocorrer juntas.

Acidez fixa, ácido cítrico, pH e densidade formam um grupo correlacionado (multicolinearidade). Isso não afeta o KNN nem o Random Forest, mas pode dividir o efeito entre essas variáveis nos coeficientes da Regressão Logística.

Em relação à classe de alta qualidade, as maiores correlações são com álcool (0,41), acidez volátil (-0,30), ácido cítrico (0,24) e sulfatos (0,21). Açúcar residual, SO2 livre e pH têm correlação próxima de zero. Nenhuma variável sozinha explica bem a qualidade, o que justifica o uso de modelos multivariados.

3.5 Comparação entre as classes

Variável	Baixa/média	Alta	Diferença
citric acid	0,250	0,387	+54,5%
volatile acidity	0,555	0,393	-29,2%
total sulfur dioxide	47,83	36,67	-23,3%
chlorides	0,089	0,074	-16,8%
sulphates	0,643	0,747	+16,3%
alcohol	10,28	11,59	+12,8%
free sulfur dioxide	15,92	13,91	-12,6%
residual sugar	2,49	2,74	+10,0%
fixed acidity	8,21	8,76	+6,7%
pH	3,32	3,29	-0,9%
density	0,997	0,996	-0,1%

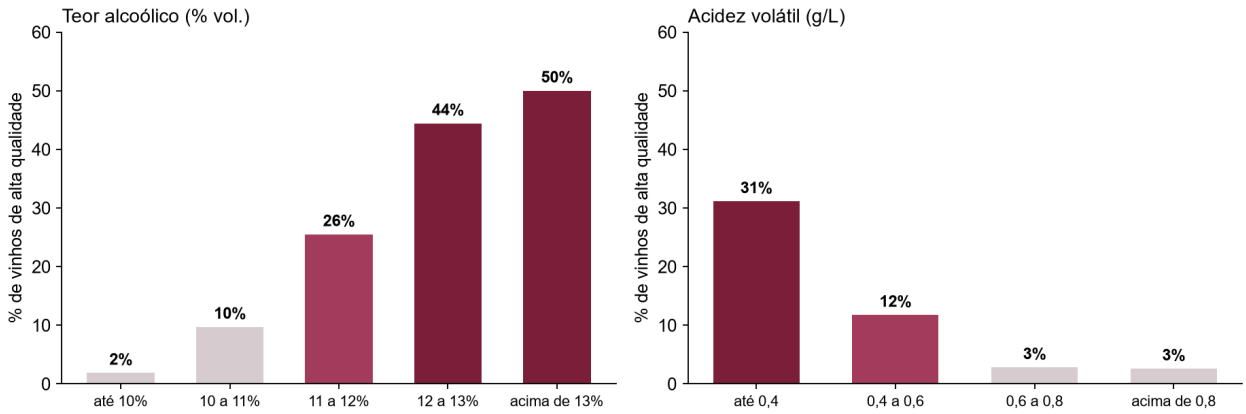


Figura 3. Proporção de vinhos de alta qualidade por faixa de teor alcoólico e de acidez volátil.

A proporção de vinhos de alta qualidade sobe de 1,9% entre os vinhos com até 10% de álcool para 44% na faixa de 12 a 13%. No sentido oposto, cai de 31% entre os vinhos com acidez volátil até 0,4 g/L para menos de 3% acima de 0,6 g/L. Combinando os dois sinais, 53% dos 117 vinhos com álcool a partir de 11,5% e acidez volátil abaixo de 0,5 g/L são de alta qualidade, cerca de quatro vezes a média da base.

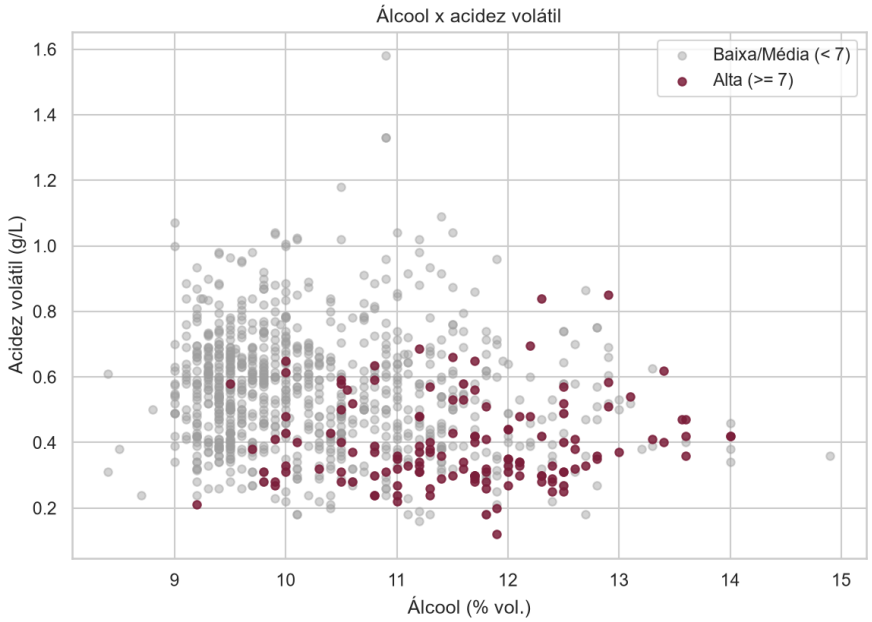


Figura 4. Álcool x acidez volátil. Os vinhos de alta qualidade se concentram na região de mais álcool e menos acidez volátil.

MODELAGEM

4. Metodologia

4.1 Pré-processamento

- Remoção das duplicadas e das colunas Id e quality.
- Criação de três variáveis: acidez total (fixa + volátil + cítrico), proporção de acidez volátil na acidez total e proporção de SO2 livre no SO2 total. Como são calculadas linha a linha, não causam vazamento.
- Divisão estratificada em 80% para treino (814 vinhos) e 20% para teste (204 vinhos), com random_state=42.
- Escalonamento dentro de um Pipeline do scikit-learn, para que seja ajustado apenas com dados de treino em cada rodada da validação cruzada. No KNN comparamos normalização Min-Max e padronização; na Regressão Logística usamos padronização; o Random Forest dispensa escalonamento.

As novas variáveis foram mantidas porque melhoraram o F1 médio na validação cruzada:

Modelo de referência	F1 (11 variáveis)	F1 (14 variáveis)	Ganho
KNN (k=15)	0,332	0,393	+0,061
Regressão Logística	0,519	0,517	-0,002
Random Forest	0,505	0,521	+0,017

4.2 Validação e escolha de hiperparâmetros

Todas as decisões de modelagem foram tomadas com validação cruzada estratificada de 5 folds no conjunto de treino, usando o F1 da classe de alta qualidade como critério. O conjunto de teste foi usado uma única vez, na avaliação final. Como referência, calculamos também um baseline que sempre prevê a classe majoritária.

Modelo	Busca	Configuração escolhida
KNN	k ímpar de 1 a 51, Min-Max e padronização (loop com validação cruzada)	k = 7, Min-Max
Regressão Logística	C de 0,001 a 100 (GridSearchCV), class_weight='balanced'	C = 0,1
Random Forest	max_depth, min_samples_leaf e max_features (GridSearchCV), 300 árvores, class_weight='balanced'	max_depth = 5, min_samples_leaf = 5, max_features = 'sqrt'

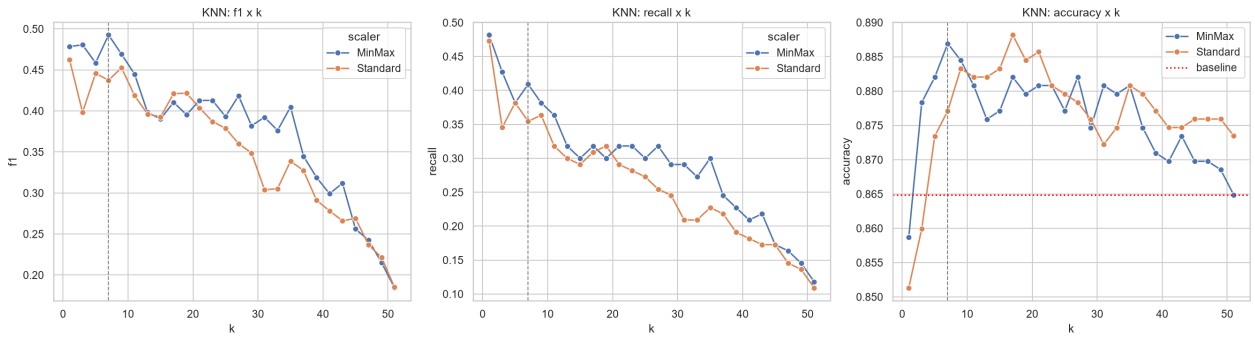


Figura 5. Escolha do k no KNN. A acurácia se mantém alta com k grande, mas o F1 e o recall caem.

A busca do k ilustra por que a acurácia não serve como critério neste problema. Escolhendo pela acurácia ficaríamos com k = 17 (F1 de 0,42 e recall de 0,31); pelo F1, com k = 7 e Min-Max (F1 de 0,49 e recall de 0,41).

4.3 Prevenção de vazamento de dados

Risco	Medida adotada
Mesmo vinho no treino e no teste	Remoção das duplicadas antes da divisão
Nota original como variável de entrada	Coluna quality removida após criar o alvo
Estatísticas do teste no escalonamento	Scaler dentro do Pipeline, ajustado só no treino
Escolha de hiperparâmetros ou do modelo pelo teste	Escolhas feitas apenas por validação cruzada no treino

RESULTADOS

5. Resultados

5.1 Validação cruzada

Média dos 5 folds no conjunto de treino. O desvio padrão é mostrado para o F1, a métrica principal.

Modelo	Acurácia	Precisão	Recall	F1	Desvio F1	ROC-AUC	PR-AUC
Baseline	0,865	0,000	0,000	0,000	0,000	0,500	0,135
KNN	0,887	0,623	0,409	0,493	0,120	0,812	0,468
Regressão Logística	0,796	0,383	0,836	0,525	0,029	0,882	0,555
Random Forest	0,834	0,435	0,755	0,551	0,068	0,877	0,561

5.2 Conjunto de teste

Modelo	Acurácia	Precisão	Recall	F1	ROC-AUC	PR-AUC
Baseline	0,868	0,000	0,000	0,000	0,500	0,132
KNN	0,912	0,737	0,519	0,609	0,865	0,527
Regressão Logística	0,789	0,357	0,741	0,482	0,886	0,484
Random Forest	0,824	0,408	0,741	0,526	0,922	0,714

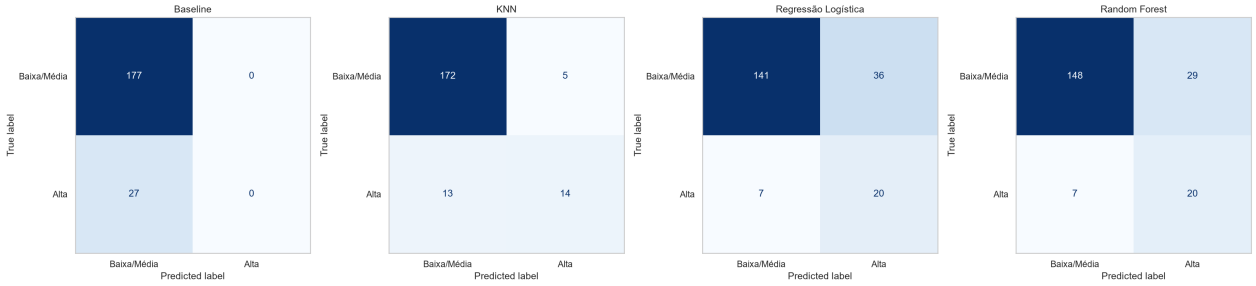


Figura 6. Matrizes de confusão no conjunto de teste.

Modelo	Vinhos bons encontrados	Falsos alarmes	Vinhos bons não encontrados
KNN	14 de 27	5	13
Regressão Logística	20 de 27	36	7
Random Forest	20 de 27	29	7

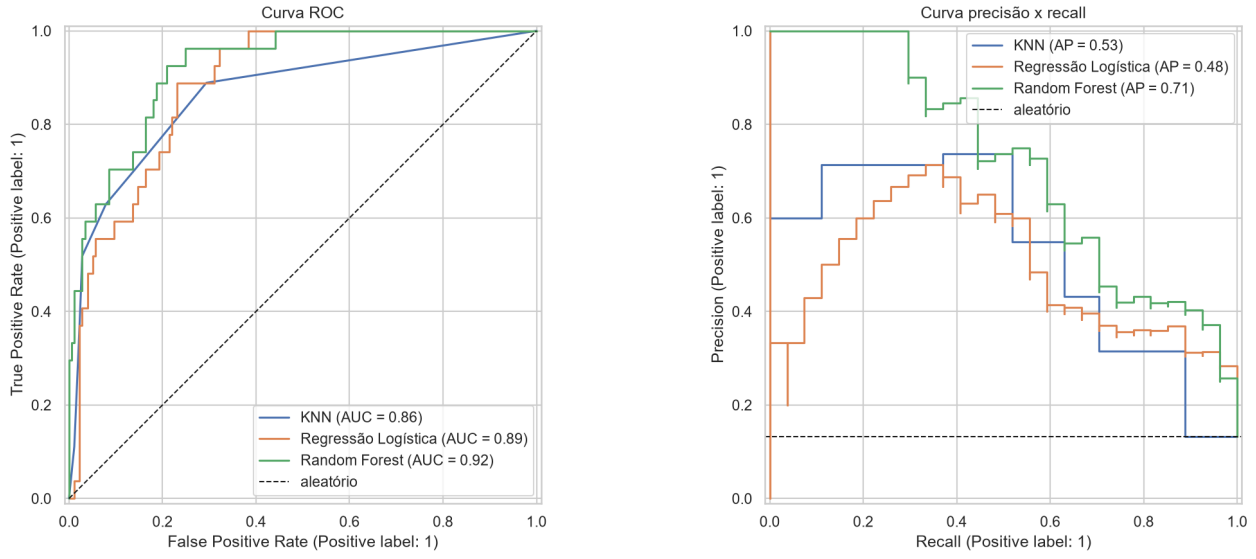


Figura 7. Curvas ROC e precisão x recall no conjunto de teste.

5.3 Discussão

Todos os modelos superam com folga o baseline, que tem a maior acurácia do teste depois do KNN mas não identifica nenhum vinho de alta qualidade.

Escolhemos o Random Forest por ter o maior F1 na validação cruzada (0,551). No teste ele também teve o melhor ROC-AUC (0,922) e PR-AUC (0,714), ou seja, é o modelo que melhor ordena os vinhos pela probabilidade de serem de alta qualidade.

O KNN teve o maior F1 no teste (0,609), mas o menor na validação cruzada (0,493) e a maior variação entre os folds. Com apenas 27 vinhos de alta qualidade no teste, um ou dois acertos a mais mudam bastante o F1, então tratamos a validação cruzada como a estimativa mais confiável. Escolher o modelo pelo resultado no teste também comprometeria a independência da avaliação.

Os modelos operam em pontos diferentes da troca entre precisão e recall. O KNN é conservador (poucos falsos alarmes, menor recall). O Random Forest e a Regressão Logística, com peso por classe, encontram mais vinhos bons à custa de mais falsos alarmes. No Random Forest esse equilíbrio pode ser ajustado pelo limiar de probabilidade, sem novo treinamento:

Limiar	Vinhos bons encontrados (de 27)	Falsos alarmes	Precisão	Recall	F1
0,3	26	48	0,35	0,96	0,51
0,4	24	37	0,39	0,89	0,55
0,5	20	29	0,41	0,74	0,53
0,6	19	18	0,51	0,70	0,59
0,7	15	6	0,71	0,56	0,62

A tabela é apenas ilustrativa. Se o limiar for ajustado em produção, a escolha deve ser feita com validação cruzada no treino e de acordo com o custo de cada tipo de erro para o negócio.

INTERPRETAÇÃO

6. Interpretação

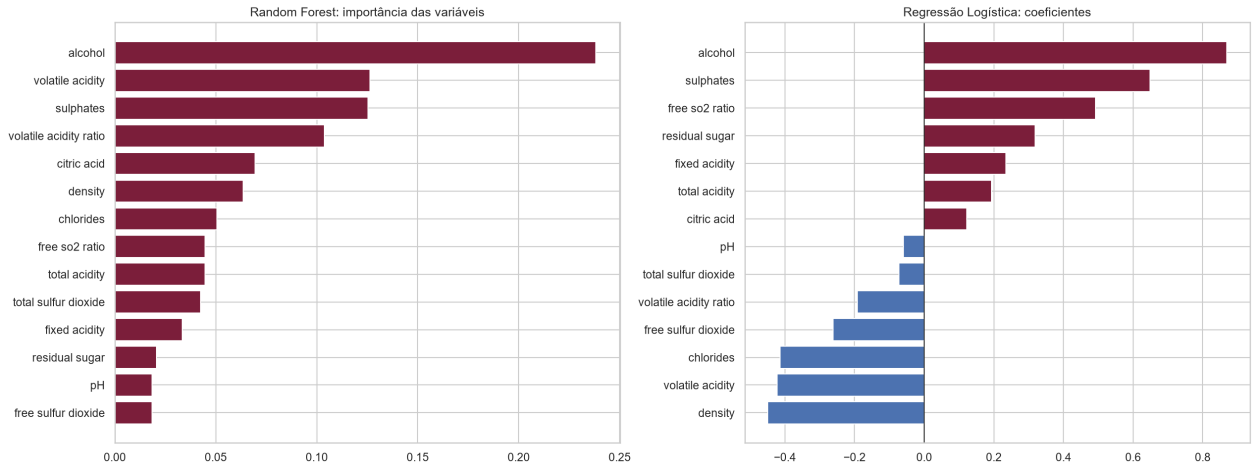


Figura 8. Importância das variáveis no Random Forest e coeficientes da Regressão Logística (variáveis padronizadas).

Variável	Importância (RF)	Coeficiente (RL)	Odds ratio (RL)
alcohol	0,238	0,869	2,39
volatile acidity	0,126	-0,422	0,66
sulphates	0,125	0,648	1,91
volatile acidity ratio	0,104	-0,193	0,82
citric acid	0,069	0,123	1,13
density	0,063	-0,450	0,64
chlorides	0,051	-0,414	0,66
free so2 ratio	0,045	0,492	1,64

O teor alcoólico é a variável mais importante nos dois modelos. Na Regressão Logística, o odds ratio de 2,39 indica que um desvio padrão a mais de álcool multiplica por esse fator a chance de o vinho ser de alta qualidade, mantidas as demais variáveis.

Acidez volátil (efeito negativo) e sulfatos (efeito positivo) aparecem em seguida. A proporção de acidez volátil, criada na engenharia de variáveis, também tem peso relevante no Random Forest e reforça o papel da acidez volátil. Na Regressão Logística, a proporção de SO2 livre tem efeito positivo, sugerindo que a eficiência do conservante importa mais do que a quantidade total. O ácido cítrico perde importância nos modelos porque parte da sua informação já está na acidez volátil, com a qual é correlacionado.

RECOMENDAÇÕES

7. Implicações para a produção

Frente	Achado	Recomendação
Colheita e fermentação	Álcool é o fator mais associado à qualidade	Colher a uva no ponto certo de maturação e garantir uma fermentação completa.
Controle da acidez volátil	Acidez volátil alta praticamente elimina a chance de alta qualidade	Higiene, controle de temperatura e menor contato com oxigênio. Monitorar a acidez volátil como indicador de alerta.
Conservantes	Sulfatos ajudam; SO2 total alto aparece mais nos vinhos piores	Buscar a menor dose eficaz, priorizando a proporção de SO2 livre e respeitando os limites legais.
Triagem de lotes	O modelo encontra 74% dos vinhos de alta qualidade no teste	Usar o modelo para priorizar a avaliação sensorial e direcionar lotes para a linha premium.

Próximos passos

- Piloto com lotes de uma safra real, comparando as previsões com a avaliação dos especialistas.
- Ajuste do limiar de decisão de acordo com o custo de cada tipo de erro.
- Ampliação da base com outras uvas, regiões e safras, e inclusão de variáveis de processo.

Limitações

- Os modelos mostram associações, não relações de causa e efeito. Mudanças no processo devem ser testadas antes.
- A base contém apenas vinhos tintos de uma origem (Vinho Verde, Portugal) e 137 vinhos de alta qualidade.
- Faltam variáveis relevantes, como tipo de uva, safra e tempo de envelhecimento.
- A nota é resultado de avaliação sensorial e carrega a variação natural entre avaliadores.

CONCLUSÃO

8. Conclusão

As medições físico-químicas permitem antecipar, com desempenho útil, quais vinhos tendem a ser de alta qualidade. A análise exploratória mostrou que teor alcoólico e acidez volátil são os sinais mais claros, e os modelos confirmaram esses fatores, junto com os sulfatos, como os mais relevantes.

O Random Forest foi o modelo escolhido: no teste identificou 74% dos vinhos de alta qualidade, com ROC-AUC de 0,92, em um problema em que apenas 13,5% dos vinhos pertencem à classe de interesse. Em todas as etapas tomamos cuidado para evitar vazamento de dados, de modo que os resultados reflitam o desempenho esperado em vinhos novos.

Referências

- Wine Quality Dataset. Kaggle. https://www.kaggle.com/datasets/yasserh/wine-quality-dataset
- Cortez, P.; Cerdeira, A.; Almeida, F.; Matos, T.; Reis, J. Modeling wine preferences by data mining from physicochemical properties. Decision Support Systems, v. 47, n. 4, p. 547-553, 2009.
- Pedregosa, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825-2830, 2011.

O código completo, o notebook com todas as saídas e a apresentação executiva estão no repositório do projeto.